

终点诊断：事实记住了，组合是否可用

固定128k步 · 全量结果与1024题评测子集分别显示 · 每行先平均同世界初始化，再对世界等权

							全量留出题数 / 每个世界
	单跳事实	训练组合	全量留出主指标	留出子集 probe	外部逐跳调用	OOD组合小样本	
两跳 · 配对比较 · 1层	100.00	100.00	27.78	—	100.00	1.45	748 / 760 / 769
两跳 · 配对比较 · 2层	100.00	100.00	96.44	—	100.00	2.28	748 / 760 / 769
两跳 · 配对比较 · 3层	100.00	100.00	98.40	—	100.00	2.90	748 / 760 / 769
两跳 · 配对比较 · 4层	100.00	100.00	98.29	—	100.00	0.72	748 / 760 / 769
两跳 · 配对比较 · 1层宽180	100.00	100.00	24.52	—	100.00	2.90	748 / 760 / 769
两跳 · 开发 · 2层	100.00	100.00	97.08	—	100.00	0.00	754
两跳 · 开发 · 4层	100.00	100.00	98.94	—	100.00	7.14	754
三跳 · 开发 · 1层	99.80	97.71	18.00	16.02	99.80	0.00	5629
三跳 · 开发 · 2层	100.00	100.00	72.62	70.31	100.00	0.00	5629
三跳 · 开发 · 3层	100.00	100.00	88.42	87.99	100.00	0.00	5629
三跳 · 开发 · 4层	100.00	100.00	95.03	94.04	100.00	0.00	5629
三跳 · 独立世界 · 3层	100.00	100.00	90.29	90.09	100.00	0.00	5677 / 5571
三跳 · 独立世界 · 4层	100.00	100.00	97.04	96.44	100.00	0.00	5677 / 5571
三跳 · 首轮开发 · 4层	100.00	100.00	9.91	11.43	100.00	0.00	5629
四跳 · 首轮开发 · 6层	100.00	100.00	7.15	7.91	100.00	0.00	42556
四跳 · 扩大组合训练 · 6层	100.00	100.00	11.84	10.55	100.00	0.00	42556

外部逐跳调用提供了关系分解并增加调用次数；两跳在全量留出集评价，三/四跳只在1024题probe评价，不能等同于单次回答。

OOD链的原子事实已训练，但未参与组合训练；每世界仅1–23题，单列保留，不能与ID主指标合并。缺失子集列表示未另设probe。

三跳1层的单跳与训练组合尚未完全拟合；两跳3层有一条训练组合错1/5838题。低留出分数需要结合这些训练前提解释。